

# Razvrščanje z dominantnimi množicami - povzetek

Taja Debeljak, Anže Marinko

Finančni praktikum

Finančna matematika, Fakulteta za matematiko in fiziko

Jesen 2017

## 1 Uvod

Grupiranje (ang. Clustering) je postopek razvrščanja predmetov znotraj razreda v podrazrede (cluster) tako, da so si predmeti znotraj istega podrazreda bolj podobni med sabo, kot so si podobni z elementi iz ostalih podrazredov.

Problem združevanja lahko opišemo z uteženim grafom, ki ga definiramo kot trojico  $G = (V, E, \omega)$ , kjer je  $V = 1, \dots, n$  končna množica vozlišč,  $E \subseteq V \times V$  množica usmerjenih povezav in  $\omega : E \rightarrow \mathbb{R}$  funkcija, ki vsakemu vozlišču dodeli neko vrednost (težo). Vozlišča grafa  $G$  ustrezajo predmetom, ki jih je potrebno združevati.

Povezave predstavljajo, kateri predmeti so med seboj povezani, utežene povezave pa odražajo podobnosti med povezanimi predmeti. Poleg tega matrika  $A_{i,j} = \omega(i, j)$  za vse  $i, j \in V$  predstavlja podobnost med vozlišči. Imenujemo jo matrika podobnosti.

Osnovni lastnosti, ki morata zadostovati gruči, sta:

- Notranja homogenost: elementi, ki pripadajo gruči si morajo biti med seboj podobni
- Maksimalnost: gruče ne moremo dodatno razširiti z uvedbo zunanjih elementov

**Definicija 1.1** Naj graf  $G$  predstavlja primer združevanja množic in naj bo  $C \subseteq V$  neprazna podmnožica. Povprečna utežena vhodna stopnja glede na  $C$  je definirana kot

$$awindeg_C(i) = \frac{1}{|C|} \sum_{j \in C} A_{i,j}$$

kjer  $|C|$  predstavlja velikost množice  $C$ . Za  $j \in C$  definiramo

$$\phi_C(i, j) = A_{i,j} - awindeg_C(j)$$

Funkcija  $\phi_C(i, j)$  je mera relativne podobnosti elementa  $i$  z elementom  $j$  glede na povprečno povezanost elementa  $i$  z elementi iz  $C$ .

Težo elementa  $i$  glede na množico  $C$  definiramo kot

$$W_C(i) = \begin{cases} 1 & ; \text{če } |C| = 1, \\ \sum_{j \in C \setminus i} \phi_{C \setminus i}(i, j) W_{C \setminus i}(j) & ; \text{sicer.} \end{cases}$$

Vrednost  $W_C(i)$  nam pove koliko podpore prejme element  $i$  od elementov  $C \setminus \{i\}$  glede na skupno podobnost z elementi iz  $C \setminus \{i\}$ . Pozitivne vrednosti nam povedo da je  $i$  močno koleriran z  $C \setminus \{i\}$ .

Skupna teža množice  $C$  pa je definirana z

$$W(C) = \sum_{i \in C} W_C(i)$$

**Definicija 1.2** Dominantna množica

Neprazni množici  $C \subseteq V$  za katero je  $W(T) > 0$  za vsako neprazno množico  $T \subseteq C$  pravimo dominantna množica, če velja:

1.  $W_C(i) > 0$  za vse  $i \in C$
2.  $W_{C \cup \{i\}}(i) < 0$  za vse  $i \notin C$

## 2 Povezava s teorijo optimizacije

Če se omejimo na simetrične povezanosti, torej  $A$  je simetrična matrika, potem lahko dominantno množico zapišemo kot rešitev naslednjega standardnega kvadratičnega programa

$$\max f(x) = x^T A x \quad (1)$$

$$\text{p. p. } x \in \Delta \subset \mathbb{R}^n \quad (2)$$

Kjer je  $\Delta = \{x \in \mathbb{R}^n : \sum_{j \in V} x_j = 1 \text{ in } x_j \geq 0 \text{ za vsak } j \in V\}$  standardni simpleks iz  $\mathbb{R}^n$ .

Pravimo, da je  $x$  rešitev zgornjega problema če obstaja soseščina  $x$ -a  $U \subseteq \Delta$  za katero je  $f(x) > f(z)$  za vsak  $z \in U \setminus \{x\}$ . Podpora  $\sigma(x)$  za  $x \in \Delta$  je definirana kot indeksna množica pozitivnih komponenta vektorja  $x$ , torej  $\sigma(x) = \{i \in V : x_i > 0\}$ .

**Definicija 2.1** Otežen vektor

Za neprazno podmnožico  $C$  množice  $V$  lahko definiramo otežen vektor  $x^C \in \Delta$ , če ima množica  $C$  pozitivno skupno težo  $W(C)$ . V tem primeru je

$$x_i^C = \begin{cases} \frac{W_C(i)}{W(C)} & ; \text{ če } i \in C, \\ 0 & ; \text{ sicer.} \end{cases}$$

Za dominantno množico lahko torej vedno definiramo otežen vektor.

**Izrek 1** Če je  $C$  dominantna množica  $A$ , potem je njen otežen vektor  $x^C$  rešitev zgornjega problema. Obratno, če je  $x^*$  rešitev zgornjega problema, potem je njegova podpora  $\sigma = \sigma(x^*)$  dominantna množica od  $A$  pri pogoju, da je  $W_{\sigma \cup \{i\}}(i) \neq 0$  za vse  $i \notin \sigma$ .